

MICA: ASSISTENTE COMPUTACIONAL MULTIMODAL BASEADO EM VISÃO COMPUTACIONAL E AGENTES INTELIGENTES PARA AUTOMAÇÃO DE TAREFAS E AUMENTO DE PRODUTIVIDADE NO SENAI

LINHA DE PESQUISA DE INTERESSE: INTELIGÊNCIA ARTIFICIAL

1. PROBLEMA DE PESQUISA

Em ambientes operacionais, laboratoriais e educacionais do SENAI Pernambuco, colaboradores, instrutores e alunos interagem continuamente com uma diversidade de softwares de alta complexidade (ex.: sistemas CAD/CAM, ERPs, softwares de controle de bancadas de ensaio e plataformas de gestão educacional). A execução de rotinas administrativas e técnicas nesses contextos impõe uma elevada carga cognitiva e uma significativa ineficiência operacional, decorrente da necessidade de alternar manualmente entre interfaces gráficas de usuário (GUI), consultar documentações extensas e replicar sequências repetitivas de comandos no computador.

Sistemas tradicionais de Automação Robótica de Processos (RPA - *Robotic Process Automation*) apresentam limitações estruturais diante desse cenário: dependem de rotinas rígidas pré-programadas, mapeamento estático de coordenadas de tela e APIs estruturadas que raramente estão disponíveis em softwares legados ou em ambientes dinâmicos de bancada. Por outro lado, o surgimento de agentes autônomos baseados em Modelos de Linguagem e Visão (VLMs - *Vision-Language Models*) abre a oportunidade de construir assistentes capazes de 'enxergar' a interface do computador e raciocinar sobre as intenções expressas em linguagem natural.

Diante dessa lacuna tecnológica e operacional, este trabalho formula a seguinte **pergunta de pesquisa**:

Pergunta de Pesquisa: *Em que medida uma arquitetura de assistente inteligente multimodal — que integra percepção visual de interface (GUI Parsing), processamento de comandos em linguagem natural por voz e agentes autônomos de automação — reduz o tempo de execução de tarefas, a taxa de erros operacionais e a carga cognitiva percebida por usuários no ecossistema operacional e educacional do SENAI Pernambuco?*

2. HIPÓTESE E PRESSUPOSTO DE PESQUISA

Pressuposto de Pesquisa: A integração sinérgica entre a interpretação estruturada de telas (GUI) por visão computacional e o planejamento de ações por agentes inteligentes orientados a ferramentas (*Tool-Use Agents*) possibilita a tradução precisa de comandos verbais imprecisos em rotinas determinísticas de interface, superando as rigidezes do RPA convencional sem requerer APIs proprietárias.

Hipótese Testável: A utilização da arquitetura MICA na execução de tarefas operacionais e administrativas padronizadas no SENAI PE reduz o Tempo de Ciclo da Tarefa (TCT) em pelo menos

30% e diminui a Taxa de Erro Operacional (TEO) em pelo menos 50% em comparação com a execução estritamente manual, mantendo um índice de usabilidade percebida (SUS) superior a 75 pontos.

3. JUSTIFICATIVA E RELEVÂNCIA

Problema Real e Relevância para o SENAI PE: O SENAI Pernambuco é referência em educação profissional e serviços tecnológicos para a indústria. A otimização de rotinas burocráticas e operacionais nos laboratórios de ensino e setores administrativos libera tempo qualificado dos docentes para o ensino e reduz o retrabalho em relatórios técnicos e ensaios laboratoriais.

Relevância Científica e Tecnológica: A pesquisa aborda um problema central na área de Interação Humano-Computador (IHC) e Agentes de IA: o acoplamento entre percepção de GUI em tempo real e controle autônomo de periféricos (*Agentic Automation*). Enquanto a literatura atual foca majoritariamente em cenários sintéticos ou benchmarks de navegação web, esta proposta investiga o comportamento de agentes multimodais em sistemas computacionais heterogêneos da indústria e do ensino técnico.

Potencial de Transferência Tecnológica: A proposta garante a transferência direta de tecnologia para o SENAI PE mediante a entrega de uma biblioteca modular e de um protótipo operacional documentado, alinhando a academia diretamente às demandas de inovação do setor produtivo.

4. OBJETIVOS

4.1. Objetivo Geral

Investigar, projetar, implementar e avaliar empiricamente a arquitetura MICA (*Multimodal Intelligent Computer Assistant*), analisando os impactos do uso combinado de visão computacional de tela e agentes inteligentes de automação sobre o tempo de execução, a taxa de erros e a usabilidade em tarefas operacionais do SENAI Pernambuco.

4.2. Objetivos Específicos

1. Mapear e formalizar os fluxos e cenários operacionais repetitivos de maior relevância técnica e administrativa nos ambientes do SENAI PE.
2. Projetar o módulo de **Percepção Visual de Interface** para realizar o *parsing* estruturado de telas (detecção de elementos interativos e OCR) e mapear coordenadas de GUI dinamicamente.
3. Desenvolver o **Motor de Agente de Automação (Agentic Engine)** para traduzir comandos de linguagem natural em sequências de ações simuladas de teclado e mouse (*Tool Use*).
4. Construir o pipeline de **Interação por Voz e Contexto Conversacional** integrado a um gerenciador de memória de trabalho para acompanhamento de sessões operacionais.
5. Conduzir um **experimento controlado de avaliação** com usuários do SENAI PE, quantificando os ganhos de produtividade (TCT, TEO) e a satisfação do usuário (SUS).

5. CONTRIBUIÇÕES ESPERADAS

Para evitar que o trabalho seja confundido com um mero desenvolvimento de software comercial, a pesquisa delimita explicitamente suas três dimensões de contribuição:

- **Contribuição Científica:** Formalização dos trade-offs entre a acurácia no *parsing* visual de interfaces gráficas não padronizadas e a taxa de sucesso na execução de tarefas por agentes de IA orientados a ferramentas, preenchendo uma lacuna de avaliação empírica de agentes de GUI em ambientes industriais/educacionais.

- **Contribuição Tecnológica:** Arquitetura aberta, modular e extensível de assistente multimodal que integra modelos de visão, linguagem e agentes de automação sem dependência de APIs proprietárias da aplicação hospedeira.
- **Contribuição Prática para o SENAI PE:** Protótipo funcional validado em ambiente real, transferência tecnológica com documentação completa e relatório de recomendações para adoção em larga escala.

6. DELIMITAÇÃO DO ESCOPO

Para garantir a exequibilidade rigorosa do projeto no prazo de 24 meses do Mestrado Profissional, o escopo foi delimitado priorizando o núcleo de pesquisa e tratando componentes auxiliares como tecnologias de infraestrutura:

- **Núcleo Científico/Tecnológico da Pesquisa:** O módulo de *GUI Parsing* (visão computacional para identificação e mapeamento semântico de botões, campos e caixas de texto) e o motor de planejamento do agente (*Action Planner*).
- **Tecnologias de Suporte e Infraestrutura:** Modelos pré-treinados de conversão de fala em texto (STT/Whisper) e síntese neural de voz (TTS), bem como bibliotecas padrão de simulação de periféricos (PyAutoGUI/pynput), serão reutilizados diretamente via API/código aberto, sem a intenção de pesquisar novos algoritmos de reconhecimento de voz.

7. REVISÃO DA LITERATURA E ESTADO DA ARTE

A fundamentação teórica organiza-se em quatro eixos temáticos que sustentam a solução proposta e evidenciam a lacuna existente na literatura:

7.1. Compreensão de Interfaces Gráficas (GUI Parsing) por Visão Computacional: A interpretação de telas evoluiu do OCR tradicional para abordagens de detecção e segmentação baseadas em redes profundas (YOLO, SAM). Trabalhos recentes em *GUI element detection* demonstram que modelos treinados em layouts de software conseguem identificar componentes interativos com alta acurácia. Contudo, a generalização para softwares industriais legados com paletas de cores não convencionais ainda é um desafio em aberto.

7.2. Vision-Language Models e Agentes Orientados a Ferramentas (*Tool Use*): O avanço dos VLMs e dos agentes baseados em LLMs permitiu a tradução de intenções de alto nível em chamadas de funções organizadas (*Function Calling*). Arquiteturas de agentes como ReAct e chamadas encadeadas de ferramentas viabilizam o planejamento passo a passo. A literatura aponta que a principal falha desses agentes ocorre no alinhamento entre a intenção planejada e as coordenadas físicas da tela.

7.3. Automação de Interfaces (Agentic RPA) e Interação Multimodal: O RPA tradicional baseia-se em seletores DOM ou coordenadas fixas, tornando-se frágil a atualizações de software. O *Agentic RPA* emerge como uma evolução resiliente, utilizando visão e raciocínio para navegar autonomamente. A adição da modalidade de voz (STT/TTS) amplia a acessibilidade e reduz o tempo de entrada de comandos em bancadas operacionais.

7.4. Lacuna da Literatura: Poucos estudos analisam empiricamente o desempenho e a usabilidade de assistentes multimodais de GUI em cenários reais de treinamento técnico e operação industrial, com usuários reais e tarefas de alta complexidade. O MICA posiciona-se exatamente para preencher esta lacuna.

8. METODOLOGIA DE PESQUISA E DESENHO EXPERIMENTAL

A metodologia adota uma abordagem de pesquisa aplicada, com ciclo de desenvolvimento iterativo e avaliação experimental quantitativa e qualitativa. A execução está dividida em 4 fases:

Fase 1: Mapeamento de Requisitos e Formalização de Fluxos (Meses 1 a 4)

Entrevistas e observação direta no SENAI PE para selecionar 3 fluxos operacionais representativos (ex.: geração de relatórios de ensaio, cadastro de parâmetros em software de bancada e consulta/preenchimento de dados de gestão).

Fase 2: Arquitetura e Desenvolvimento Modular do MICA (Meses 5 a 12)

Construção dos módulos de visão (GUI Parser), motor de agentes (*Action Planner*) e pipeline de voz/memória em ambiente controlado.

Fase 3: Integração e Testes Controlados de Bancada (Meses 13 a 18)

Integração da pipeline *end-to-end* assíncrona. Ajuste fino de comandos e otimização da latência de resposta do sistema.

Fase 4: Avaliação Experimental e Validação de Campo no SENAI PE (Meses 19 a 24)

Execução do experimento com usuários e análise estatística dos dados coletados.

8.1. Desenho do Experimento de Avaliação

O experimento adotará um design pareado *within-subjects* (dentro dos sujeitos), no qual um grupo de N = 15 a 20 participantes (instrutores e colaboradores do SENAI PE) executará os fluxos operacionais selecionados em duas condições experimentais:

- Condição Controle (Manual):** Execução tradicional da tarefa pelo usuário utilizando mouse, teclado e consulta a manuais.
- Condição Tratamento (Assistido pelo MICA):** Execução da tarefa com o auxílio do assistente MICA por comandos de voz e automação visual.

8.2. Métricas de Avaliação

Métrica	Definição Operacional	Instrumento / Coleta	Meta Experimental
Tempo de Ciclo (TCT)	Tempo total (segundos) do início ao término do fluxo.	Logs automáticos do sistema	Redução $\geq 30\%$
Taxa de Erro (TEO)	Número de ações incorretas ou preenchimentos errôneos.	Contagem por observador/log	Redução $\geq 50\%$
Taxa de Conclusão	Percentual de tarefas concluídas com sucesso.	Registro binário (Sucesso/Falha)	Alcançar $\geq 90\%$
Usabilidade (SUS)	Pontuação de usabilidade percebida (escala de 0 a 100).	Questionário SUS pós-teste	Atingir SUS > 75

9. RISCOS, LIMITAÇÕES E ASPECTOS ÉTICOS

9.1. Limitações Técnicas e Riscos Mapeados: (i) Variações dinâmicas de layout ou resoluções de tela que possam dificultar a detecção de elementos pelo *GUI Parser*; (ii) Latência do processamento visual e inferência dos modelos de linguagem; (iii) Ruído ambiente nos laboratórios do SENAI afundando a acurácia do STT; (iv) Riscos de execução inadvertida de comandos involuntários no sistema operacional.

9.2. Mitigações e Aspectos de Segurança/Ética: O sistema incorporará um mecanismo obrigatório de confirmação humana (*Human-in-the-Loop*) para ações de alto risco e uma chave de interrupção imediata (*Kill Switch*). O processamento de imagens de tela e voz respeitará a LGPD, garantindo o anonimato das capturas e o não armazenamento de dados sensíveis dos participantes. Os testes serão

conduzidos sob termo de consentimento livre e esclarecido.

10. CRONOGRAMA DE EXECUÇÃO (24 MESES / 8 TRIMESTRES)

Etapa / Atividade	T1	T2	T3	T4	T5	T6	T7	T8
1. Disciplinas do Programa e Revisão Bibliográfica	X	X	X					
2. Mapeamento de Requisitos e Fluxos no SENAI PE		X	X					
3. Desenvolvimento dos Módulos do MICA			X	X	X			
4. Exame de Qualificação de Mestrado					X			
5. Integração e Testes em Laboratório						X		
6. Avaliação Experimental e Validação no SENAI							X	
7. Redação da Dissertação e Defesa Final							X	X

11. REFERÊNCIAS BIBLIOGRÁFICAS

ANTHROPIC. **Building Effective Agents**. Technical Report, Anthropic Research, 2024.

KIRILLOV, A. et al. **Segment Anything**. In: IEEE/CVF International Conference on Computer Vision (ICCV), p. 4015-4026, 2023.

RADFORD, A. et al. **Robust Speech Recognition via Large-Scale Weak Supervision**. In: International Conference on Machine Learning (ICML), PMLR, p. 28492-28518, 2023.

REDMON, J. et al. **You Only Look Once: Unified, Real-Time Object Detection**. In: IEEE Conference on Computer Vision and Pattern Recognition (CVPR), p. 779-788, 2016.

SHAHNIRAM, M. et al. **GUI Automation Agents: A Survey on Vision-Language Models for Desktop and Mobile Interaction**. ACM Computing Surveys, v. 56, n. 4, p. 1-35, 2024.

UNIVERSIDADE FEDERAL DE PERNAMBUCO. **Edital nº 01/2026 — Seleção para o Programa de Pós-Graduação Profissional em Ciências da Computação**. Recife: CIn-UFPE, 2026.

YANG, J. et al. **Set-of-Mark Prompting Unleashes Extraordinary Visual Grounding in Visual Store-Language Models**. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024.

12. PRINCIPAIS ALTERAÇÕES REALIZADAS (SÍNTESE DAS MELHORIAS)

Em estrito cumprimento ao roteiro de otimização acadêmica fornecido, a proposta original do MICA passou por uma reestruturação científica profunda para elevar sua competitividade no processo seletivo de Mestrado Profissional do CIn-UFPE:

- 1. **Formulação de Pergunta e Hipótese de Pesquisa:** O projeto deixou de ser apresentado como uma mera proposição de software para estruturar-se em torno de uma pergunta científica objetiva sobre a eficácia da multimodalidade e uma hipótese testável comparando o MICA à execução manual.
- 2. **Diferenciação das Contribuições:** Isolaram-se explicitamente as contribuições científicas (avaliação de trade-offs em GUI Parsing), tecnológicas (arquitetura aberta) e práticas (ferramenta transferida ao SENAI PE).
- 3. **Delimitação Rígida do Escopo para 24 Meses:** Reduziu-se o esparramamento tecnológico definindo o módulo de *GUI Parsing* e o *Action Planner* como núcleo da pesquisa, enquanto componentes de voz (STT/TTS) e simulação de periféricos foram rebaixados a tecnologias de infraestrutura reutilizadas de

mercado.

4. Desenho Experimental Científico e Defensável: A metodologia foi reestruturada em um experimento pareado *within-subjects* com métricas consolidadas (TCT, TEO, Taxa de Conclusão e SUS) e amostra definida de usuários no SENAI PE.

5. Inclusão de Riscos, Limitações e Ética: Adicionaram-se salvaguardas de segurança (*Human-in-the-Loop*, *Kill Switch*) e conformidade com a LGPD e o edital do certame.